



**APRENDIZAJE AUTOMÁTICO: TERCER CURSO  
DEL GRADO  
DE ING. INFORMÁTICA EN COMPUTACION**



**Clasificación: K-vecinos más  
cercanos: K-NN**

**César Hervás-Martínez  
Grupo de Investigación AYRNA**

**Departamento de Informática y Análisis  
Numérico  
Universidad de Córdoba  
Campus de Rabanales. Edificio Einstein.  
Email: [chervas@uco.es](mailto:chervas@uco.es)**

**2019-2020**



# INTRODUCCION

## K-NN (K-NEAREST NEIGHBOUR)



- Un nuevo caso se va a clasificar en la clase más frecuente a la que pertenecen sus K vecinos más cercanos
- Idea muy simple e intuitiva
- Fácil implementación
- No hay modelo explícito
- Razonamiento basado en casos “*Case Based Reasoning*” (CBR)



# INTRODUCCION

## K-NN (K-NEAREST NEIGHBOUR)

### Notación para el paradigma K-NN



		$X_1$	...	$X_j$	...	$X_n$	$C$
$(x_1, c_1)$	1	$x_{11}$	...	$x_{1j}$	...	$x_{1n}$	$c_1$
	.	.		.		.	.
	.	.		.		.	.
	.	.		.		.	.
$(x_i, c_i)$	i	$x_{i1}$	...	$x_{ij}$	...	$x_{in}$	$c_i$
	.	.		.		.	.
	.	.		.		.	.
	.	.		.		.	.
$(x_N, c_N)$	N	$x_{N1}$	...	$x_{Nj}$	...	$x_{Nn}$	$c_N$
$x$	N+1	$x_{N+1,1}$	...	$x_{N+1,j}$	...	$x_{N+1,n}$	?



# K-NN (K-NEAREST NEIGHBOUR)



## Pseudocódigo para el clasificador K-NN

El algoritmo K-NN básico

**COMIENZO**

**Entrada:**  $D = \{(x_1, c_1), \dots, (x_N, c_N)\}$

**$x = (x_1, \dots, x_n)$  nuevo caso a clasificar**

**PARA todo objeto ya clasificado  $(x_i, c_i)$**

**calcular  $d_i = d(x_i, x)$**

**Ordenar  $d_i (i = 1, \dots, N)$  en orden ascendente**


**Quedarnos con los K casos  $D_x^K$  ya clasificados  
más cercanos a  $x$**

**Asignar a  $x$  la clase más frecuente en  $D_x^K$**

**FIN**



# ALGORITMO K-NN BÁSICO




$N=21$  N° de patrones  
 $n=2$  N° de variables  
 $K=3$   
 $m=2$  N° de clases

**Ejemplo de aplicación del algoritmo K-NN básico**



## ALGORITMO K-NN BÁSICO: Ejemplo 1NN



Dado el siguiente ejemplo con 4 instancias, 3 variables independientes y dos clases:

- $(x_1)=(1.4,0.8,1.2)$ , y  $(x_2)=(1.2,0.7,1.9)$  de la clase positiva
- $(x_3)=(1.0,0.8,0.9)$  y  $(x_4)=(0.8,1.0,0.0)$  de la clase negativa

Calcular la etiqueta del clasificador del vecino más cercano (1NN) con respecto al patrón de etiqueta desconocida  $(x)=(0.7,1.2,1.3)$

$$d(\mathbf{x}_1, \mathbf{x}) = \sqrt{\sum_{i=1}^3 (x_{1i} - x_i)^2} = \sqrt{((1.4 - 0.7)^2 + (0.8 - 1.2)^2 + (1.2 - 1.3)^2)} = 0.81$$

$$d(\mathbf{x}_2, \mathbf{x}) = \sqrt{\sum_{i=1}^3 (x_{2i} - x_i)^2} = \sqrt{((1.2 - 0.7)^2 + (0.7 - 1.2)^2 + (1.9 - 1.3)^2)} = 0.93$$

$$d(\mathbf{x}_3, \mathbf{x}) = \sqrt{\sum_{i=1}^3 (x_{3i} - x_i)^2} = \sqrt{((1.0 - 0.7)^2 + (0.8 - 1.2)^2 + (0.9 - 1.3)^2)} = 0.64$$

$$d(\mathbf{x}_4, \mathbf{x}) = \sqrt{\sum_{i=1}^3 (x_{4i} - x_i)^2} = \sqrt{((0.8 - 0.7)^2 + (1.0 - 1.2)^2 + (0.0 - 1.3)^2)} = 1.32$$


De esta forma el patrón  $x$  pertenece a la clase negativa. ¿Y si  $K$  fuera igual a 2?



# ALGORITMO K-NN BÁSICO



Porcentaje de  
patrones bien  
clasificados



**Ejemplo de la no monotonicidad del  
porcentaje de patrones bien clasificados en función de K**



## VARIANTES DEL ALGORITMO K-NN



Hay distintas variantes del algoritmo en función de cómo calculamos la clase a partir de los K vecinos más cercanos:

- **Voto por mayoría** (*majority voting*).
- **Voto ponderado**: en función de la distancia el voto vale más o menos (más peso cuando la distancia sea más pequeña).
- En el caso del uso de votos ponderados, es frecuente que relajemos la restricción de los K vecinos y en muchos casos se usan todos los ejemplos del conjunto de datos.

### Variantes del algoritmo K-NN básico

- K-NN con rechazo
- K-NN con distancia media
- K-NN con distancia mínima
- K-NN con ponderación de vecinos
- K-NN con ponderación de variables





## K-NN CON RECHAZO

**Para clasificar un caso se exigen ciertas garantías, por ejemplo distancia mínima.**

- **Si no se tienen puedo dejar el caso sin clasificar**
- **Umbral prefijado**
- **Mayoría absoluta**



## K-NN CON DISTANCIA MEDIA



**Ejemplo de ilustración del algoritmo K-NN con distancia media**



## K-NN con distancia mínima

**Seleccionar un caso por clase (p.e. el más cercano al centroide de la clase)**

- Reducción de la dimensión del fichero almacenado de  $N$  a  $m$
- Ejecutar un 1-NN a dicho fichero reducido
- Efectividad condicionada a la homogeneidad dentro de las clases (menor varianza). A mayor homogeneidad más efectivo



## K-NN con ponderación de vecinos



	$D(x_i, x)$	$w_i$
x1	2	$\frac{1}{2}=0,5$
x2	2	0,5
x3	2	0,5
x4	2	0,5
x5	0,7	$1/0,7$
x6	0,8	$1/0,8$

K=6

**Peso a asignar a cada uno de los 6 casos seleccionados**

**Ejemplo de ilustración del K-NN con ponderación de casos seleccionados**

**Votos para clase “o”:  $0.5 + 0.5 + 0.5 + 0.5 = 2$**

**Votos para clase “+”:  $1.43 + 1.25 = 2.68$**

**Predicción “+”**



## K-NN con ponderación de vecinos

**Mismo peso a todas las variables:**

$$d(\mathbf{x}, \mathbf{x}_r) = \sum_{j=1}^n (x_j - x_{rj})^2$$

• **Distinto peso a cada variable:**

$$d(\mathbf{x}, \mathbf{x}_r) = \sum_{j=1}^n w_j (x_j - x_{rj})^2$$

• **Determinar  $w_j$  a partir de la Cantidad de Información mutua entre  $X_j$  y  $C$   $I(X_j, C)$**



# K-NN con ponderación de variables



X1	X2	C
0	0	1
0	0	1
0	0	1
1	0	1
1	0	1
1	1	1
0	1	0
0	1	0
0	1	0
1	1	0
1	1	0
1	0	0

$$I(X_1, C) = \sum_{i=1}^n \sum_{j=1}^m p(x_{1i}, c_j) \log_2 \frac{p(x_{1i}, c_j)}{p(x_{1i}) p(c_j)}$$

$$I(X_1, C) = P_{(x_1, C)}(0, 0) \log_2 \frac{P_{(x_1, C)}(0, 0)}{P_{x_1}(0) P_C(0)} + P_{(x_1, C)}(0, 1) \log_2 \frac{P_{(x_1, C)}(0, 1)}{P_{x_1}(0) P_C(1)} +$$

$$+ P_{(x_1, C)}(1, 0) \log_2 \frac{P_{(x_1, C)}(1, 0)}{P_{x_1}(1) P_C(0)} + P_{(x_1, C)}(1, 1) \log_2 \frac{P_{(x_1, C)}(1, 1)}{P_{x_1}(1) P_C(1)} =$$

$$= \frac{3}{12} \log_2 \frac{\frac{3}{12}}{\frac{6}{12} \cdot \frac{6}{12}} + \frac{3}{12} \log_2 \frac{\frac{3}{12}}{\frac{6}{12} \cdot \frac{6}{12}} + \frac{3}{12} \log_2 \frac{\frac{3}{12}}{\frac{6}{12} \cdot \frac{6}{12}} + \frac{3}{12} \log_2 \frac{\frac{3}{12}}{\frac{6}{12} \cdot \frac{6}{12}} =$$

$$= \frac{3}{12} \log_2 \frac{12}{12} + \frac{3}{12} \log_2 \frac{12}{12} + \frac{3}{12} \log_2 \frac{12}{12} + \frac{3}{12} \log_2 \frac{12}{12} = 0$$

**La variable X1 no es relevante para determinación de la clase C**



## K-NN con ponderación de variables



$$I(X_2, C) = \sum_{i=1}^n \sum_{j=1}^m p(x_{2i}, c_j) \log_2 \frac{p(x_{2i}, c_j)}{p(x_{2,i}) p(c_j)}$$

X1	X2	C
0	0	1
0	0	1
0	0	1
1	0	1
1	0	1
1	1	1
0	1	0
0	1	0
0	1	0
1	1	0
1	1	0
1	0	0

$$\begin{aligned}
 I(X_2, C) &= P_{(x_2, C)}(0, 0) \log_2 \frac{P_{(x_2, C)}(0, 0)}{P_{x_2}(0) P_C(0)} + P_{(x_2, C)}(0, 1) \log_2 \frac{P_{(x_2, C)}(0, 1)}{P_{x_2}(0) P_C(1)} + \\
 &+ P_{(x_2, C)}(1, 0) \log_2 \frac{P_{(x_2, C)}(1, 0)}{P_{x_2}(1) P_C(0)} + P_{(x_2, C)}(1, 1) \log_2 \frac{P_{(x_2, C)}(1, 1)}{P_{x_2}(1) P_C(1)} = \\
 &= \frac{1}{12} \log_2 \frac{\frac{1}{12}}{\frac{6}{12} \cdot \frac{6}{12}} + \frac{5}{12} \log_2 \frac{\frac{5}{12}}{\frac{6}{12} \cdot \frac{6}{12}} + \frac{5}{12} \log_2 \frac{\frac{5}{12}}{\frac{6}{12} \cdot \frac{6}{12}} + \frac{1}{12} \log_2 \frac{\frac{1}{12}}{\frac{6}{12} \cdot \frac{6}{12}} = \\
 &= -\frac{1}{6} \log_2 3 + \frac{5}{6} \log_2 5 - \frac{5}{6} \log_2 3 = -\log_2 3 + \frac{5}{6} \log_2 5
 \end{aligned}$$

mientras que la variables X2 si lo es



# SELECCIÓN DE PROTOTIPOS

## EDICIÓN DE WILSON



- Someter a prueba a cada uno de los elementos del fichero de casos inicial.
- Para cada caso se compara su clase verdadera con la que propone un clasificador K-NN obtenido con todos los casos excepto el mismo.
- Si ambas clases no coinciden, el caso es eliminado.
- Edición de Wilson repetitiva parando el procedimiento cuando en 2 selecciones sucesivas no se produzcan cambios.





# SELECCIÓN DE PROTOTIPOS

## CONDENSACIÓN DE HART



**Para cada caso, y siguiendo el orden en el que se encuentran almacenados los casos en el fichero, se construye un clasificador K-NN con tan sólo los casos anteriores al caso en cuestión**

- **Si el caso tiene un valor de la clase distinto al que le asignaría el clasificador K-NN, el caso es seleccionado**
- **Si por el contrario la clase verdadera del caso coincide con la propuesta por el clasificador K-NN, el caso no se selecciona.**
- **El método es dependiente del orden en que se encuentren almacenados los casos en el fichero**



**APRENDIZAJE AUTOMÁTICO: TERCER CURSO  
DEL GRADO  
DE ING. INFORMÁTICA EN COMPUTACION**



# **Clasificación: K-vecinos más cercanos:K-NN**

**César Hervás-Martínez  
Grupo de Investigación AYRNA**

**Departamento de Informática y Análisis  
Numérico  
Universidad de Córdoba  
Campus de Rabanales. Edificio Einstein.  
Email: [chervas@uco.es](mailto:chervas@uco.es)**

**2019-2020**



# OneR



**OneR: clasificador con reglas que solo tienen una variable en el antecedente.**

- Para atributos discretos (en Weka se discretizan los numéricos).
- Se genera un conjunto de reglas del tipo:
- Si  $variable=valor$  entonces Clase = categoría.

## **ALGORITMO OneR**

**Para cada atributo  $a$ :**

**Para cada valor del atributo  $v$ :**

**Contar cuantas veces aparece cada etiqueta en ejemplos en los que  $a=v$ .**

**Encontrar la etiqueta más frecuente ( $c_{max}$ ).**

**Crear una regla Si  $a=v$  entonces Clase= $c_{max}$ .**

**Fin Para**

**Calcular el error de aplicar todas las reglas de  $a$ .**

**Fin Para**

**Devolver las reglas del atributo  $a$  con menor error.**